# Revista GEOCIÊNCIAS



ISSN: 1980-900X (online)

# APLICAÇÃO DE REDES NEURAIS ARTIFICIAIS PARA PREVISÃO DO NÍVEL DE ÁGUA SUBTERRÂNEA EM POÇO DE MONITORAMENTO NA BACIA SEDIMENTAR DO ARARIPE, CEARÁ

APPLICATION OF ARTIFICIAL NEURAL NETWORKS FOR GROUNDWATER LEVEL FORECASTING ON MONITORING WELL IN ARARIPE SEDIMENTARY BASIN, CEARÁ

# Rubens Oliveira da CUNHA JÚNIOR<sup>1</sup>, Paulo Renato Alves FIRMINO<sup>2</sup>

<sup>1</sup>Universidade Federal do Cariri, Centro de Ciências Agrárias e Biodiversidade. Rua Ícaro de Sousa Moreira - São José, Crato – CE. E-mail: cunhajunior.rubens@gmail.com

<sup>2</sup>Centro de Ciências e Tecnologia, Universidade Federal do Cariri. Avenida Tenente Raimundo Rocha, 1639 - Cidade Universitária, Juazeiro do Norte – CE. E-mail: paulo.firmino@ufca.edu.br

Introdução
Procedimentos metodológicos
Área de estudo e conjunto de dados
Redes neurais artificiais
Modelagem da série temporal
Desenho do estudo
Resultados e discussão
Conclusão
Referências

**RESUMO** - A previsão dos níveis de água subterrânea é fundamental para a avaliação da disponibilidade hídrica. Formalismos como Redes Neurais Artificiais (RNA) são amplamente utilizados na modelagem e previsão de séries temporais. O objetivo do presente trabalho foi avaliar a aplicação de modelos RNAs para previsão dos níveis de água em um poço instalado no Sistema Aquífero Médio, na bacia sedimentar do Araripe, Ceará. Foram utilizadas RNA *feedforward* com uma camada oculta. Utilizando os valores passados da série como entradas nos modelos, investigou-se a melhor arquitetura das redes quanto ao número de nós nas camadas de entrada e oculta. Os modelos foram aplicados segundo abordagens de modelagem individual e combinadas, através da combinação linear de preditores, como a Média Simples e a Mediana Simples. Seus desempenhos foram avaliados segundo métricas estatísticas conhecidas, como o RMSE e o R². Os resultados obtidos evidenciam o bom desempenho das RNAs, com RMSE = 0,032 m e R² = 0,99. Os modelos individuais superaram as combinações. O presente trabalho mostrou como RNAs são modelos eficientes para a previsão do nível da água subterrânea, mesmo em sistemas complexos e com poucas variáveis de entrada, constituindo uma ferramenta com grande aplicabilidade para gestão dos recursos hídricos subterrâneos.

Palavras-chave: Previsão de séries temporais. Combinação linear de preditores. Redes neurais artificiais. Bacia Sedimentar do Araripe.

**ABSTRACT** - Groundwater level forecasting is essential for water availability. Formalisms such as Artificial Neural Networks (ANN) are broadly used to time series modeling and forecasting. The aim of this paper was to evaluate the application of ANN models for forecasting groundwater level of one well installed at Medium Aquifer System in Araripe sedimentary basin, Ceará. Feedforward ANN models with one hidden layer were applied. By using the time series past values as model inputs, the optimal network architecture was searched, with respect to the number of nodes on input and hidden layers. The ANN models were applied according to single and combined modeling approaches, through linear combination of forecasts, such as Simple Average and Simple Median. The model performances were measured and compared by well-known statistics metrics, such as RMSE and  $R^2$ . Results highlight the ANN good performance, with RMSE = 0,032 m and  $R^2$  = 0,99. Single models outperformed combinations. This research showed how ANN are efficient models for forecasting groundwater level, even on complex systems and with a few input variables, representing a tool with large applicability on groundwater resources management.

Keywords: Time series forecasting. Linear combination of forecasts. Artificial neural networks. Araripe Sedimentary Basin.

# INTRODUÇÃO

O uso racional e sustentável dos recursos hídricos é fundamental para o desenvolvimento sustentável (Council, 1999). Neste sentido, estratégias para a gestão integrada da água proporcionam o controle e preservação deste recurso, e garantem a resolução de conflitos relacionados aos seus múltiplos usos em todas as fases do ciclo hidrológico (Tucci, 2001). Um importante instrumento para a gestão e planejamento dos recursos hídricos são os programas de monitoramento. Essencial para a avaliação da disponibilidade

hídrica, o monitoramento das águas subterrâneas fornece informações que dão suporte ao processo de tomada de decisão.

Através de observações sistemáticas dos níveis da água em poços e de parâmetros de qualidade da água em poços monitorados, pode-se acompanhar os estados quantitativo e qualitativo das reservas. Em especial, a compreensão da evolução histórica dos níveis é fundamental para a previsão da disponibilidade hídrica (Feitosa, 2008).

No semiárido brasileiro, em virtude das carac-

terísticas climáticas e do regime intermitente dos recursos hídricos superficiais, as águas subterrâneas constituem uma importante alternativa para o acesso a água (Campos & Studart, 2001). No estado do Ceará, as regiões extremo sul e litoral do estado possuem uma hidrogeologia sedimentar de boa permeabilidade que favorece a ocorrência de reservas de água subterrânea (Teixeira, 2003). Em especial, ao sul do estado encontra-se a porção leste da bacia sedimentar do Araripe, a maior reserva de água subterrânea do Ceará (COGERH, 2009). Inserida no contexto da região do Cariri, os sistemas aquíferos da bacia são a principal fonte de abastecimento de água da região, sendo o Aquífero Médio o mais importante e o mais explorado. Diante disso, as águas subterrâneas são um fator condicionante ao desenvolvimento regional (Veríssimo, 1999).

Neste contexto, formalismos como séries temporais têm sido amplamente empregados no processo de modelagem e previsão de variáveis hidrológicas passíveis de acompanhamento histórico (Machiwal & Jha, 2012). O estudo de séries temporais tem aplicações em diversas áreas do conhecimento, uma vez que permite entender a natureza estocástica de fenômenos, identificar padrões e prever valores futuros a partir do histórico conhecido (Morettin & Toloi, 1981). Os recentes avanços computacionais impulsionaram o desenvolvimento de técnicas de análise e otimização com grande aplicabilidade, inclusive

na análise de séries temporais (Palit & Popovic, 2005). Destaca-se o Aprendizado de Máquina, um ramo da Inteligência Artificial que dispõe de um conjunto de algoritmos utilizados em problemas de classificação e previsão. Modelos como as Redes Neurais Artificiais (RNAs) possuem a capacidade de aprender através de um processo de treinamento, e baseado nisto, generalizar o aprendizado obtido a fim de prever cenários ou eventos futuros (Awad & Khanna, 2015).

Destaca-se entre os modelos de RNA mais comumente utilizados para previsão as redes perceptron multicamadas (MLP, do inglês multilayer perceptron) (Haykin, 1999). A construção destes modelos envolve a determinação da arquitetura e do algoritmo de aprendizado da rede que levem aos melhores resultados na previsão (Zhang, 2001). No tocante à previsão dos níveis de água subterrânea, a aplicação das RNAs foi investigada por autores como Coulibaly et al. (2001), Daliakopoulos et al. (2005), Nayak et al. (2006), Mohanty et al. (2010), Yoon et al. (2011) e Gong et al. (2016), Lee et al. (2019) e Derbela & Nouiri (2020), e os obtidos evidenciaram resultados desempenho das redes. Diante do exposto, o presente trabalho avaliou o uso de RNAs para previsão do nível de água subterrânea, através da modelagem dos níveis em um poço instalado sobre o sistema Aquífero Médio, da Bacia Sedimentar do Araripe.

# PROCEDIMENTOS METODOLÓGICOS

#### Área de estudo e conjunto de dados

A área de estudo está localizada na região do Cariri, ao sul do estado do Ceará, no município de Abaiara. Está inserida na sub-bacia hidrográfica do rio Salgado, pertencente ao alto curso da bacia do Rio Jaguaribe, e pertence ao contexto hidrogeológico da porção leste da Bacia Sedimentar do Araripe. O poço selecionado (Figura 1) é monitorado pela Rede Integrada de Monitoramento de Águas Subterrâneas – RIMAS (RIMAS, 2021), com o número de identificação 2300022895. Está instalado sobre o sistema Aquífero Médio e localizado nas coordenadas geográficas -39,0156; -7,39075, na cota de terreno 398 m.

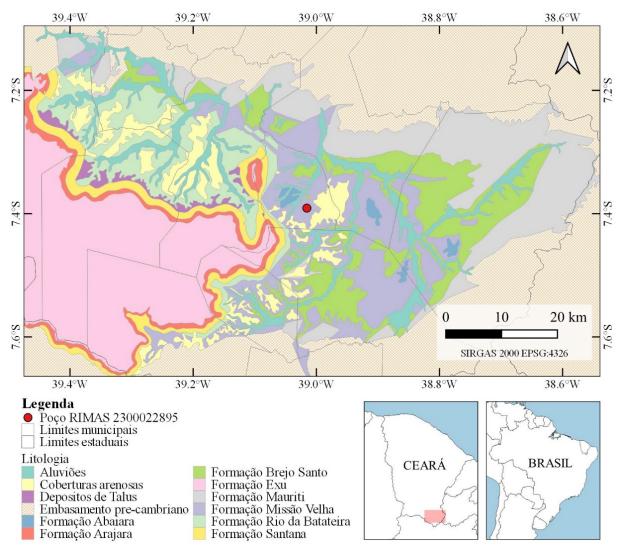
A hidrogeologia da região possui uma litoestratigrafia diversificada, com uma alternância de sistemas aquíferos, aquitardos e aquicludes. Segundo a COGERH (2009), adota-se a seguinte divisão hidrogeológica da Bacia Sedimentar do Araripe: (i) Sistema Aquífero Superior (formações

Exu e Arajara); (ii) Aquiclude Santana (formação homônima); (iii) Sistema Aquífero médio (formações Rio da Batateira, Abaiara e Missão Velha); (iv) Aquiclude Brejo Santo (formação homônima); (v) Sistema Aquífero inferior (Formação Mauriti e parte da Formação Brejo Santo). A Figura 2 mostra a localização do poço de monitoramento e a caracterização hidrogeológica da área de estudo.

O regime pluviométrico da região é caracterizado por uma grande irregularidade interanual e pela variabilidade temporal e espacial das chuvas. A precipitação média anual na região do Cariri é 919,6 mm, com chuvas concentradas entre os meses de fevereiro a maio (Teixeira, 2003). O clima é definido como tropical quente semiárido brando, tropical quente e tropical quente subúmido. O relevo é formado por dois domínios principais, o planalto da Chapada do Araripe, e a depressão do Vale do Cariri (COGERH, 2009).



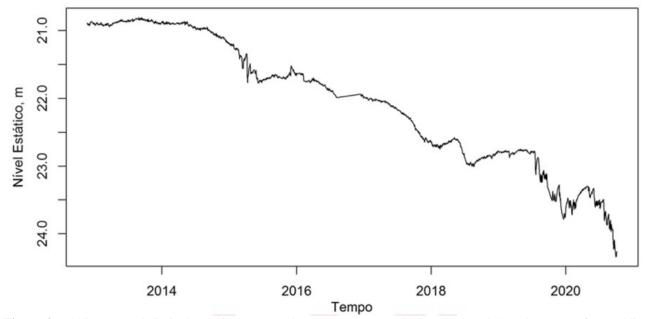
Figura 1 – Poço de monitoramento no município de Abaiara, Ceará (Fonte: RIMAS, 2021).



**Figura 2** – Localização do poço de monitoramento e caracterização hidrogeológica da porção leste da bacia sedimentar do Araripe (Fonte: CPRM, 2005, e COGERH, 2009).

Foi considerada a série histórica de 2.876 observações diárias dos níveis de água no poço selecionado, correspondendo ao período de 21 de novembro de 2012 até 5 de outubro de 2020. Os dados foram obtidos do portal RIMAS na internet (RIMAS, 2021). A série apresentou falhas no

registro dos dados, totalizando 127 dias sem dados, no período compreendido de 9 de agosto de 2016 até 13 de dezembro de 2016, que foram preenchidos por interpolação linear simples. A Figura 3 mostra a série temporal utilizada no presente estudo.



**Figura 3** – Série temporal diária de níveis de água subterrânea no poço selecionado, instalado sobre o Aquífero Médio, na bacia do Araripe, no período de 21/09/2012 a 5/10/2020 (Fonte: RIMAS, 2021).

#### Redes neurais artificiais

Redes neurais artificiais (RNAs) são sistemas de processamento baseados no funcionamento do cérebro humano. Estes modelos possuem a capacidade de aprender a partir do armazenamento de conhecimento experimentado, e de generalizar tal conhecimento adquirido, a fim de realizar previsões de cenários ou eventos futuros. O funcionamento das RNAs se dá através de uma rede de interconexões entre unidades básicas de processamento, análogas aos neurônios. As redes feedforward de multicamadas, mais conhecidas como perceptron multicamadas (MLPs) amplamente utilizadas em problemas previsão. Este modelo é formado por nós interconectados e dispostos em diversas camadas, de entrada, ocultas e de saída, de modo que cada camada se conecta à camada posterior (Haykin, 1999; Palit & Popovic, 2005; Awad & Khanna, 2015).

A determinação da arquitetura da rede MLP é uma etapa fundamental para a aplicação de redes neurais. Para a previsão de séries temporais univariadas, geralmente são utilizados valores passados da série como entradas da rede. Por conta disso, neste caso a MLP pode ser vista como um modelo autorregressivo não linear.

Então, o número de nós na camada de entrada é determinado pelo número de valores passados utilizados no modelo autorregressivo (Zhang, 2001; Palit & Popovic, 2005).

Uma rede MLP com uma camada oculta possui boa capacidade de generalização e bom desempenho na previsão de séries temporais. Entretanto, a determinação do número de nós na camada oculta é um processo de tentativa e erro, variando-se o número de nós até alcançar o melhor resultado. Para a previsão um passo adiante, é necessário apenas um nó na camada de saída (Zhang, 2001; Palit & Popovic, 2005). A Figura 4 mostra uma rede MLP para previsão um passo adiante de séries temporais univariadas. Destaque-se que Y<sub>1</sub> representa o valor da série no instante t. A rede mostrada na Figura 1 pode ser expressa matematicamente pela Equação (1).

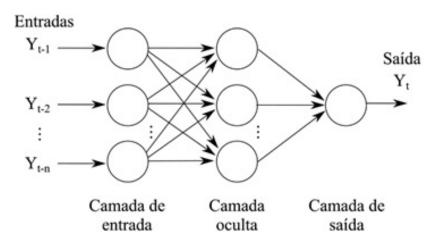
$$Y_{t} = f\left(\sum_{h}^{n_{h}} w_{ho} \cdot f\left(\sum_{i}^{n_{i}} w_{ih} Y_{i} + b_{h}\right) + b_{o}\right) (1)$$

Onde os índices i, h e o se referem às camadas de entrada, oculta e de saída, respectivamente.  $Y_i$  e  $Y_t$  representam as entradas e a saída,  $n_i$  e  $n_h$  o número de nós de entrada e saída, respectivamente. w são os pesos das conexões ente os nós

e b são constantes de viés (bias).

A função f é chamada função de ativação, que permite a aplicação da rede para processos não lineares. Entre as funções de ativação comumente utilizadas, destaca-se a função logística (Lee et al., 2019).

O processo de aprendizagem de uma RNA se dá através de uma etapa de treinamento, onde o conjunto de dados disponível é dividido em dois subconjuntos, um de treinamento e outro de teste. O subconjunto de treinamento é usado para construção do modelo, enquanto que o de teste é usado para mensurar a capacidade de previsão do modelo. Neste processo, os pesos sinápticos das interconexões da rede são alterados de acordo com os dados inseridos nas entradas, de modo a atingir o objetivo esperado. Entre os algoritmos de aprendizado supervisionado, o algoritmo backpropagation é amplamente utilizado no treinamento de redes MLP (Palit & Popovic, 2005).



**Figura 4** - Arquitetura básica de uma rede neural artificial *feedforward* para previsão de séries temporais univariadas com uma camada oculta.

#### Modelagem da série temporal

A definição das variáveis da camada de entrada da rede é uma das etapas mais importantes na construção de modelos RNAs. Para a previsão de níveis de água subterrânea, geralmente são empregadas como entradas variáveis hidrometeorológicas e valores passados dos níveis (Coulibaly et al., 2001). A utilização dos valores passados da série como variáveis de entrada da RNA constitui uma opção eficaz para a previsão do nível da água subterrânea (Yoon et al., 2011). Desse modo, o presente trabalho investigou a aplicação de RNAs utilizando valores passados da série para a modelagem e previsão dos níveis no poço selecionado no aquífero Médio.

A construção de modelos autorregressivos de séries temporais envolve o estudo da relação de dependência existente entre os seus valores. A determinação da defasagem do modelo pode ser auxiliada pela análise dos gráficos de autocorrelação (FAC) e de autocorrelação parcial (FACP). A autocorrelação mede a correlação linear existente entre os valores da série Y<sub>t</sub> e Y<sub>t-k</sub>, onde *k* é o número da defasagem. Desde que existe uma correlação entre Y<sub>t</sub> e Y<sub>t-1</sub>, então também deve haver entre Y<sub>t-1</sub> e Y<sub>t-2</sub>. Entretanto, uma possível

correlação entre  $Y_t$  e  $Y_{t-2}$ , deve existir simplesmente porque ambos têm correlação com  $Y_{t-1}$ , e não por  $Y_{t-2}$  ser de fato significante para o modelo. Portanto, para contornar isto, a autocorrelação parcial mede a relação entre  $Y_t$  e  $Y_{t-k}$  desconsiderando os efeitos das defasagens 1,2, ..., k-1 (Hyndman & Athanasopoulos, 2018).

Os modelos RNA se destacam entre os formalismos mais populares utilizados para previsão de séries temporais. Entretanto, pode-se encontrar na literatura estudos destacando o uso de formalismos de modelagem combinada e o seu bom desempenho, melhorando a precisão e eficiência dos modelos individuais (Messias et al., 2016).

Destacam-se entre estas estratégias os combinadores lineares, como a Média Simples (SA) e a Mediana Simples (SM) (Firmino et al., 2014).

A modelagem combinada leva em consideração as estimativas  $u_t$  geradas pelos k modelos individuais, para um determinado valor a que se deseja prever. O modelo SA consiste na média aritmética simples dos k modelos individuais, e o modelo SM é a mediana simples dos k modelos individuais. A mediana representa o valor que separa um conjunto de dados ordenados em duas metades (Sales, 2019).

#### Desenho do estudo

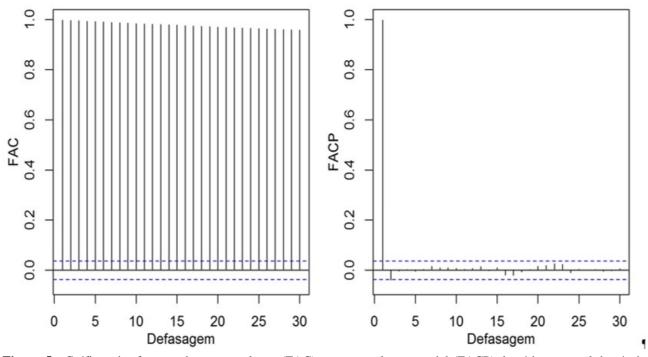
O presente estudo dedicou-se à previsão do nível de água subterrânea com uso de redes neurais artificiais (RNAs), através da modelagem da série temporal de níveis de um poço instalado sobre o sistema Aquífero Médio, na Bacia do Araripe. Foram realizadas simulações computacionais a fim de se determinar a melhor arquitetura para as redes *perceptron* multicamadas (MLPs), no tocante a definição do número de nós nas camadas de entrada e oculta.

A etapa inicial do estudo constituiu uma abordagem de modelagem simples de séries temporais. Em um segundo momento, técnicas de modelagem combinada foram aplicadas e seus desempenhos avaliados.

As simulações foram realizadas em ambiente de programação estatística R (Team, 2022), e os modelos foram construídos utilizando o pacote *neuralnet* (Günther & Fritsch, 2010). A série foi previamente submetida a uma normalização do tipo Min-Max e transformada para uma escala de 0 a 1, de modo a se adequar às entradas das redes (Palit & Popovic, 2005). Foi adotado o algo-

ritmo de aprendizado *backpropagation* resiliente ("rprop+") e a função de ativação logística (Günther & Fritsch, 2010). A série foi dividida em dois subconjuntos: um subconjunto para a etapa de treinamento do modelo (80% iniciais da série) e o de teste, para avaliação do desempenho (20% finais da série).

Para a definição da camada de entrada dos modelos RNA, foram examinadas duas situações: nos modelos do Tipo I, as RNA não consideram a sazonalidade da série, e nos modelos do Tipo II, a sazonalidade da série é considerada. A Figura 5 mostra os gráficos da FAC e FACP da série de níveis de água subterrânea. Para os modelos do Tipo I, foram utilizadas as informações do FACP para a identificação dos termos autorregressivos. Como mostrado na Figura 5, os valores significativos da autocorrelação nas defasagens 1 e 2 indicam que os valores de Y<sub>t-1</sub> e Y<sub>t-2</sub> são recomendados para a camada de entrada da RNA. A sazonalidade do sistema foi considerada, e para os modelos do Tipo II, decidiu-se por adotar um termo autorregressivo sazonal como entrada da rede, referente à observação Y<sub>t-365</sub>.



**Figura 5** - Gráficos das funções de autocorrelação (FAC) e autocorrelação parcial (FACP) da série temporal de níveis diários em poço tubular na Bacia do Araripe.

Para a definição da camada intermediária, os modelos Tipo I e Tipo II foram testados com diferentes números de nós na camada oculta, variando-se de 1 a 10, totalizando 20 modelos simples (2 opções de camada de entrada x 10 opções de camada oculta x 1 nó da camada de

saída = 20). Por fim, a camada de saída dos modelos possui um nó. A Tabela 1 mostra os modelos avaliados no presente trabalho, bem como o número de observações da série utilizado para as etapas de treino (80% iniciais da série) e de teste (20% finais da série) em cada caso.

**Tabela 1** – Descrição dos modelos RNA construídos e tamanhos dos subconjuntos de dados utilizados nas etapas de treino e teste.

Modelo	Tamanho da série		Arquitetura da rede				
	Treino	Teste	Entrada	Camada oculta	Saída		
Tipo I	2298	574	$2(Y_{t-1} e Y_{t-2})$	1 a 10	1		
Tipo II	1935	574	$3(Y_{t-1}, Y_{t-2} e Y_{t-365})$	1 a 10	1		

A notação *i-h-o* foi utilizada para identificação dos modelos de redes neurais MLP construídos, onde *i*, *h* e *o* representam o número de nós nas camadas de entrada, oculta e de saída, respectivamente.

Em seguida, o estudo dedicou-se a avaliar a aplicação de abordagens de modelagem combinada. Foram construídos 4 modelos combinados através dos modelos SA e SM. Os conjuntos de treinamento dos modelos Tipo I e Tipo II diferem em virtude do termo sazonal adotado no modelo Tipo II. Para a combinação na etapa de treino, foram considerados apenas os pontos de dados estimados no intervalo referente ao conjunto de treino do modelo Tipo II, conforme mostrado na tabela 1.

A avaliação do desempenho dos modelos utilizou como métricas de erro a raiz do erro quadrático médio (RMSE) e o coeficiente de determinação (R²). O RMSE mede o valor médio do erro entre os pontos de dados conhecidos e os previstos pelos modelos, e é dado na mesma unidade de medida da série temporal. O coeficiente R² é uma medida de ajuste de regressão linear entre os valores observados e os previstos,

variando em um intervalo de 0 a 1, sendo 1 o valor ótimo (Yoon et al., 2011; Derbela & Nouiri, 2020). O RMSE e coeficiente R<sup>2</sup> são expressos conforme as Equações (2) e (3), respectivamente.

RMSE = 
$$\sqrt{\frac{\sum_{i=1}^{n} (P_i - O_i)^2}{n}}$$
 (2)

$$R^{2} = \frac{\sum_{i=1}^{n} (O_{i} - \overline{O})(P_{i} - \overline{P})}{\sqrt{\sum_{i=1}^{n} (O_{i} - \overline{O})^{2} \sum_{i=1}^{n} (P_{i} - \overline{P})^{2}}}$$
(3)

Onde  $O_i$  e  $P_i$  são os valores observados e previstos,  $\overline{O}$  e  $\overline{P}$  as médias dos valores observados e dos previstos, respectivamente, e n o número de total de valores.

Após a previsão, os valores previstos pelas RNAs foram transformados de volta à escala original da série e o RMSE calculado em metros. Os modelos individuais foram comparados segundo o RMSE, e aquele que apresentou o menor valor na etapa de teste entre os 20 construídos foi selecionado como o melhor. Os modelos combinados tiveram seus desempenhos comparados com os dos modelos individuais.

### RESULTADOS E DISCUSSÃO

O desempenho dos 20 modelos individuais construídos foi avaliado nas etapas de treino e de teste. A Tabela 2 mostra o RMSE para todos os modelos: os individuais organizados por tipo e os combinados. Na fase de treino, a média dos valores do RMSE para os modelos Tipo I e Tipo

II foi 0,015 m para ambos, enquanto que na fase de teste, o RMSE foi 0,115 m e 0,105 m, respectivamente. Em média, o desempenho na etapa de teste aponta que não há uma superioridade significante do Tipo II em relação ao Tipo I quanto a capacidade de generalização.

**Tabela 2** – Valores do RMSE (em metros) obtidos nas etapas de treino (TR) e teste (TS) para os modelos individuais (Tipo I e Tipo II) e combinados construídos.

RNA Tipo I	TR	TS	RNA Tipo II	TR	TS	Combinação (k)	TR	TS
2-1-1	0,016	0,175	3-1-1	0,013	0,080	SA (20)	0,015	0,108
2-2-1	0,015	0,155	3-2-1	0,016	0,124	SA (3)	0,014	0,043
2-3-1	0,016	0,118	3-3-1	0,016	0,157	SM (20)	0,015	0,117
2-4-1	0,013	0,074	3-4-1	0,017	0,130	SM (3)	0,013	0,049
2-5-1	0,015	0,140	3-5-1	0,014	0,032			
2-6-1	0,015	0,157	3-6-1	0,017	0,147			
2-7-1	0,020	0,067	3-7-1	0,014	0,098			
2-8-1	0,013	0,050	3-8-1	0,018	0,123			
2-9-1	0,014	0,099	3-9-1	0,014	0,103			
2-10-1	0,016	0,117	3-10-1	0,015	0,052			

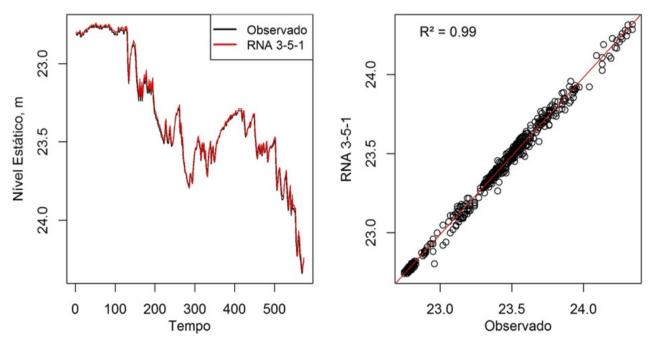
As previsões das RNAs na etapa de teste apresentaram um RMSE variando de 0,032 m a 0,175 m. Na fase de teste, entre os modelos do Tipo I, a rede 2-8-1 teve o melhor desempenho, com 0,050 m. O modelo 3-5-1 foi o melhor entre os do Tipo II, com 0,032 m. Seu desempenho foi o superior entre todos os 20 construídos, portanto foi considerado como o melhor modelo. A figura 6 mostra a análise gráfica das previsões para a etapa de teste do modelo RNA 3-5-1. O resultado revela o bom ajuste entre o observado e o estimado, e as medidas de erro utilizadas também evidenciam este bom desempenho, com um R² = 0,99. O valor de R² próximo de 1 mostra a boa qualidade do ajuste obtido.

Em comparação com outros estudos sobre previsão dos níveis de água subterrânea utilizando RNAs (Daliakopoulos et al., 2005; Nayak et al., 2006; Mohanty et al., 2010; Yoon et al., 2011), os resultados obtidos pelos modelos RNA indicam um desempenho de previsão relativamente bom, assim como os obtidos por Lee et al. (2019). Os resultados obtidos no presente trabalho indicam que as para a previsão do nível

de água subterrânea, as RNAs são capazes de obter resultados suficientemente bons mesmo com poucas variáveis de entrada, o que também foi evidenciado em trabalhos como Lee et al. (2019) e Derbela & Nouiri (2020).

Quanto às abordagens de modelagem combinada, foram avaliadas as combinações entre todos os 20 modelos individuais e entre os 3 com melhor resultado na etapa de teste. Na etapa de teste, o modelo Média Simples (SA) aplicada aos 3 melhores modelos individuais teve melhor desempenho entre as combinações, RMSE = 0,043 m. Entretanto, as combinações não superaram o desempenho do melhor modelo individual. Isto pode ser devido aos demais modelos afetarem o desempenho da combinação, apesar de se utilizar os melhores modelos individuais.

Através dos resultados obtidos no presente trabalho e as comparações com trabalhos semelhantes, evidencia-se que as RNAs são modelos eficientes para o uso na previsão dos níveis de água subterrânea, mesmo em sistemas aquíferos irregulares em regiões com alto consumo de água subterrânea, como a região do Cariri cearense.



**Figura 6** – Previsões do nível de água subterrânea pelo modelo RNA 3-5-1 no subconjunto de teste: (a) valores observados e estimados e (b) gráfico de pares entre valores observados e estimados, e o coeficiente de determinação.

#### CONCLUSÃO

No presente estudo, modelos RNA foram utilizados para previsão do nível de água subterrânea em um poço tubular instalado sobre o sistema Aquífero Médio, na bacia sedimentar do Araripe. Utilizando as informações passadas da série temporal como entradas dos modelos, abordagens de modelagem individual e combi-

nada tiveram os seus desempenhos avaliados na previsão da série temporal segundo métricas de erro como o RMSE e o R<sup>2</sup>. As medidas mostraram que os modelos individuais foram superiores, apresentando boa qualidade do ajuste obtido e desempenho relativamente bom.

Os resultados obtidos evidenciaram a efi-

ciência e precisão dos modelos RNA na previsão do nível de água subterrânea em sistemas complexos e irregulares, mesmo utilizando poucas variáveis de entrada nos modelos. Diante da importância dos recursos hídricos subterrâneo par ao desenvolvimento regional sustentável, sobretudo na região do Cariri cearense,

formalismos como as RNA aplicadas à modelagem e previsão dos níveis de água subterrânea contribuem para a avaliação da disponibilidade hídrica dos sistemas aquíferos e fornecem informações que dão subsídios para o processo de tomada de decisão na gestão integrada dos recursos hídricos.

### REFERÊNCIAS

- AWAD, M. & KHANNA, R. **Efficient Learning Machines**: Theories, concepts, and applications for engineers and system designers: Apress open, 2015.
- CAMPOS, J.N.B. & STUDART, T.M.C. Gestão de Águas: Princípios e Práticas. ABRH - Associação Brasileira de recursos Hídricos, Porto Alegre, 2001.
- COGERH. Plano de Monitoramento e Gestão dos Aquíferos da Bacia do Araripe: Estado do Ceará. Fortaleza: Companhia de Gestão dos Recursos Hídricos COGERH, CE, 2009.
- COULIBALY, P.; ANCTIL, F.; ARAVENA, R.; BOBÉE, B. Artificial neural network modeling of water table depth fluctuations. **Water resources research**, v. 37, n. 4, p. 885-896, 2001.
- COUNCIL, N. R. **Our Common Journey**: A Transition Toward Sustainability. Washington, DC: The National Academies Press. 1999.
- CPRM COMPANHIA DE PESQUISA DE RECURSOS MINERAIS SERVIÇO GEOLÓGICO DO BRASIL. Hidrogeologia da porção oriental da bacia sedimentar do Araripe: Diagnóstico do Estado da Arte. Brasil: Serviço Geológico do Brasil CPRM, 2005. Disp. em: https://rigeo.cprm.gov.br/jspui/bitstream/doc/10454/1/META\_A.PDF. Acessado em: 10/06/2021.
- DALIAKOPOULOS, I.N.; COULIBALY, P.; TSANIS, I.K. Groundwater level forecasting using artificial neural networks. **Journal of hydrology**, v. 309, n. 1-4, p. 229-240, 2005.
- DERBELA, M. & NOUIRI, I. Intelligent approach to predict future groundwater level based on artificial neural networks (ANN). **Euro-Mediterranean Journal for Environmental Integration**, v. 5, n. 3, p. 1-11, 2020.
- FEITOSA, F.A.C. **Hidrogeologia**: Conceitos e aplicações. Rio de Janeiro: CPRM, 2008.
- FIRMINO, P.R.A.; MATTOS NETO, P.S.G.; FERREIRA, T.A.E. Correcting and combining time series forecasters. **Neural Networks**, v. 50, p. 1-11, 2014.
- GONG, Y.; ZHANG, Y.; LAN, S.; WANG, H. A comparative study of artificial neural networks, support vector machines and adaptive neuro fuzzy inference system for forecasting groundwater levels near Lake Okeechobee, Florida. Water resources management, v. 30, n. 1, p. 375-391, 2016.
- GÜNTHER, F. & FRITSCH, S. neuralnet: Training of neural networks. **The R journal**, v. 2, n. 1, p. 30-38, 2010.
- HAYKIN, S. **Neural Networks**: A comprehensive foundation. [S.l.]: Prentice Hall, 1999.
- HYNDMAN, R.J. & ATHANASOPOULOS, G. **Forecasting:** principles and practice. Melbourne, Australia: OTexts, 2018. Disp. em: https://www.OTexts.com/fpp2. Acessado em: 10/06/2021.
- LEE, S.; LEE, K.K.; YOON, H. Using artificial neural network models for groundwater level forecasting and assessment of the relative impacts of influencing factors. **Hydrogeology Journal**, v. 27, n. 2, p. 567-579, 2019.
- MACHIWAL, D. & JHA, M. K. **Hydrologic Time Series Analysis**: Theory and practice. New Delhi, India: Springer, 2012.

- MESSIAS, V.R.; ESTRELLA, J.C.; EHLERS, R.; SANTANA, M.J.; SANTANA, R.C.; REIFF-MARGANIEC, S. Combining time series prediction models using genetic algorithm to autoscaling web applications hosted in the cloud infrastructure. **Neural Computing and Applications**, v. 27, n. 8, p. 2383-2406, 2016.
- MOHANTY, S.; JHA, M.K.; KUMAR, A.; SUDHEER, K.P. Artificial neural network modeling for groundwater level forecasting in a river island of eastern India. **Water resources management**, v. 24, n. 9, p. 1845-1865, 2010.
- MORETTIN, P.A. & TOLOI, C.M. C. Modelos para previsão de séries temporais. Rio de Janeiro: IMPA, 1981.
- NAYAK, P.C.; RAO, Y.R.S.; SUDHEER, K.P. Groundwater level forecasting in a shallow aquifer using artificial neural network approach. **Water resources management**, v. 20, n. 1, p. 77-90, 2006.
- PALIT, A.K. & POPOVIC, D. Computational Intelligence in Time Series Forecasting: Theory and engineering applications: Springer, 2005.
- REDE INTEGRADA DE MONITORAMENTO DE ÁGUAS SUBTERRÂNEAS RIMAS. Disp. em: http://rimasweb.cprm.gov.br/layout/. Acessado em 10/06/2021.
- SALES, J. P. DE. Modelling and forecasting sustainable development time series via single and combined approaches. Crato, 2019. Dissertação (Mestrado em Desenvolvimento Regional Sustentável) Universidade Federal do Cariri.
- TEAM, R. Core. R: A language and environment for statistical computing. 2022.
- TEIXEIRA, F.J.C. **Modelos de gerenciamento de recursos hídricos**: análises e proposta de aperfeiçoamento do sistema do Ceará. Fortaleza. 2003. Dissertação (Mestrado em Recursos Hídricos) Universidade Federal do Ceará.
- TUCCI, C.E.M. **Hidrologia: ciência e aplicação.** Porto Alegre: Ed. UFRGS, 2001.
- VERISSIMO, L.S. A importância das Águas subterrâneas para o Desenvolvimento socioeconômico do Eixo CRAJUBAR, Cariri ocidental Estado do Ceará. Fortaleza. 1999. Dissertação (Mestrado em Hidrogeologia) Universidade Federal do Ceará.
- YOON, H.; JUN, S.C.; HYUN, Y.; BAE, G.O.; LEE, K.K. A comparative study of artificial neural networks and support vector machines for predicting groundwater levels in a coastal aquifer. **Journal of hydrology**, v. 396, n. 1-2, p. 128-138, 2011.
- ZHANG, G.P. An investigation of neural networks for linear time-series forecasting. **Computers Operations Research**, v. 28, n. 12, p. 1183–1202, 2001.

Submetido em 29 de junho de 2021 Aceito para publicação em 15 de julho de 2022